Описание метода

Для решения задачи Mounting Car я выбрал алгоритм истинно онлайнового Sarsa(λ) с голландскими следами, описанного в книге Барто-Саттон в главе 12.7.

Данная задача имеет непрерывное пространство состояний s={pos, vel}. Табличное представление функции Q(s,a) – оценки ценности действия – в данном случае будет работать плохо, так как будет требовать сильной дискретизации пространства состояний. Вместо этого используется подход линейной аппроксимации этой функции с помощью алгоритма плиточного кодирования. Суть плиточного кодирования состоит в следующем: зададим над пространством s дискретную сетку, каждый гиперквадрат этой сетки назовем тайлом (tile) – каждая пара {s,a} проецируется ровно в один тайл; зададим набор m таких покрытий. Тогда каждая пара {s,a} будет проецироваться в каждом из m покрытий в какой-то свой тайл – таким образом выделяя активный набор m тайлов. Зададим каждому тайлу вес w. Тогда функция q(s,a) может быть аппроксимирована как $Q(s,a) = \sum_{i=1}^{m} w_i\, x_i(s,a) = \boldsymbol{w}^T \boldsymbol{x},$ где $\boldsymbol{x}$ – бинарный вектор признаков (является ли i-тайл активным для данной пары {s,a} или нет).

Политика π(a|s) может восстанавливаться из функции q(s,a) различными способами: это может быть жадная политика $\pi(a|s) = \begin{cases} 1, \ a = argmax_{\acute{a}}(q(s,\acute{a})) \\ 0 - \text{иначе} \end{cases}$;

это может быть e-жадная политика $\pi(a|s) = \begin{cases} 1 - \varepsilon + \frac{\varepsilon}{|A|}\ , \ a = argmax_{\acute{a}}(q(s,\acute{a})) \\ \frac{\varepsilon}{|A|} - \text{иначе} \end{cases}$

(здесь $|A|$ – размерность пространства действий);

это может быть softmax политика $\pi(a|s) = \frac{\exp\left[q(s,a)/\tau\right]}{\sum_{\acute{a}} \exp\left[q(s,\acute{a})/\tau\right]}$, где τ – “температура” .

То есть зная q(s,a) мы можем задать нужное распределение $\pi(a|s)$, из которого можем семплировать действие. В задаче я использовал e-жадную политику.

При использовании аппроксимации производится обучение весов.

Алгоритм Sarsa(λ).

Алгоритм базируется на использовании следов приемлемости (глава 12 Барто-Саттона). Это иной способ представления TD (time-difference) алгоритма, в котором q(s,a) обновляется не за счет накопления дохода от будущих состояний, а, наоборот за счет обновления состояний посещенных в прошлом. Каждому состоянию ставится в соответствие след, который активизируется при посещении данного состояния, а в других случаях он затухает с множителем **λ.** Таким образом параметр **λ** характеризует память состояния о своих прошлых посещениях и как эти посещения сказались на результирующем доходе. Это можно наглядно увидеть в выражении для замещающего следа (формула 12.12)

$$z_{i,t} = \begin{cases} 1, \text{если } x_{i,t} = 1 \\ \gamma\lambda z_{i,t-1}, \text{в противном случае} \end{cases}$$

То есть для только что посещенного состояния след приводится к своему максимальному значению, в то время как для всех других состояний след убывает.

В книге было рекомендовано вместо замещающего использовать голландский след. При его использовании средняя длина эпизода упала по сравнению с замещающим следом со 164 шагов до 110-120.

В отличие от методов Монте-Карло, которые являются оффлайновыми в том смысле, что оценку q(s,a) можно произвести только в конце эпизода, следы приемлемости являются онлайновыми так как производят обновление q(s,a) на каждом временном шаге.

Полный листинг алгоритма приведен в главе 12.7 Барто-Саттона.